

Predição de Resultados de Partidas da Copa do Mundo

Uma abordagem com ranking FIFA e desempenho pré-Copa
Integrante 1 · Integrante 2 · Integrante 3 · Integrante 4

1. Contexto, Motivação e Objetivo

A Copa do Mundo FIFA é uma das competições esportivas mais acompanhadas do mundo e oferece um cenário rico para análise de dados. Este trabalho investiga se informações disponíveis antes do início de cada torneio, como ranking FIFA e desempenho no ciclo pré-Copa, ajudam a prever o resultado das partidas.

O objetivo é construir e avaliar modelos de classificação supervisionada para prever três classes: vitória da Seleção A, empate e vitória da Seleção B.

O dataset FIFA World Cup Dataset (2002-2026), indicado nas orientações do trabalho, foi considerado como referência temática. Para adequar o problema à previsão de partidas, foi construído um dataset derivado que combina resultados internacionais e rankings semestrais da FIFA. Essa decisão permitiu calcular atributos anteriores à Copa e prever o resultado de cada jogo do torneio. A edição de 2026 não foi usada na modelagem porque ainda não possui resultados finais completos, ou seja, não há rótulos reais para treinamento ou avaliação.

As bases usadas foram: resultados internacionais de seleções, disponíveis em <https://www.kaggle.com/datasets/martj42/international-football-results-from-1872-to-2017>; ranking masculino FIFA, obtido no Kaggle em <https://www.kaggle.com/datasets/lucasyukioimafuko/fifa-mens-world-ranking>; e o dataset FIFA World Cup Dataset (2002-2026), disponibilizado como referência da disciplina.

2. Enquadramento Analítico

O problema foi tratado como classificação multiclasse. Foram avaliados baseline da classe majoritária, regressão logística, árvore de decisão e random forest. As métricas principais foram acurácia e macro-F1, sendo a macro-F1 especialmente importante por equilibrar a avaliação entre as três classes.

A abordagem segue ideias comuns em sports analytics: usar medidas de força histórica, forma recente e comparação relativa entre adversários. No futebol, rankings, desempenho ofensivo, desempenho defensivo e forma prévia são frequentemente usados como aproximações da qualidade técnica e do momento competitivo das equipes.

3. Hipóteses Sobre o Fenômeno

- H1: seleções melhor posicionadas no ranking FIFA possuem maior probabilidade de vencer.
- H2: a forma recente acrescenta informação além do ranking.
- H3: o desempenho acumulado no ciclo pré-Copa contém informação útil.
- H4: a força dos adversários recentes melhora a interpretação da forma recente.

4. Metodologia e Modelagem

O dataset derivado foi construído a partir de uma base de resultados internacionais e uma base de rankings semestrais da FIFA. Cada linha representa uma partida de Copa do Mundo entre 1998 e 2022. Para evitar vazamento de informação, os atributos foram calculados apenas com dados anteriores ao início da Copa correspondente.

A divisão temporal foi: treinamento nas Copas de 1998 a 2010, validação em 2014, teste final em 2018 e avaliação adicional em 2022. Foram removidos do treino os placares reais, o alvo e metadados como nomes das seleções e datas.

O pré-processamento incluiu padronização de nomes de seleções entre as bases, seleção das partidas de Copa, definição do ciclo pré-Copa e cálculo de estatísticas agregadas. Também foram criadas variáveis de diferença entre Seleção A e Seleção B, como diferença de ranking, pontos FIFA, aproveitamento recente, gols marcados e gols sofridos.

As ferramentas utilizadas foram Python, scikit-learn para modelagem, matplotlib e seaborn para visualizações, além de scripts próprios para geração do dataset, análise exploratória e avaliação dos modelos.

Trechos relevantes do código

O primeiro trecho mostra a prevenção de vazamento temporal: o ranking de cada seleção é buscado no semestre anterior ao início da Copa.

```
current_ranking = ranking.get_previous(team, tournament_start)
rank_year, rank_semester = ranking.previous_period(tournament_start)
```

O alvo da classificação foi gerado a partir do placar: vitória da Seleção A, empate ou vitória da Seleção B. Os placares foram removidos das variáveis explicativas usadas pelos modelos.

```
if score_a > score_b:
    result = 0
elif score_a == score_b:
    result = 1
else:
    result = 2
```

A avaliação foi organizada por tempo, usando Copas anteriores para treino e Copas posteriores para validação e teste.

```
if 1998 <= year <= 2010:
    treino.append(row)
elif year == 2014:
    validacao.append(row)
elif year == 2018:
    teste.append(row)
elif year == 2022:
    avaliacao_extra.append(row)
```

5. Dados e Resultados

O dataset final possui 448 partidas, 45 colunas e 67 seleções. Para a modelagem foram usadas 32 variáveis explicativas. A classe mais frequente é vitória da Seleção A, seguida por vitória da Seleção B e empate.

Análise Exploratória

A análise exploratória teve como objetivo compreender a composição do dataset antes da modelagem, verificar o equilíbrio entre as classes e observar relações iniciais entre força das

seleções e resultado das partidas.




Figura 1: distribuição geral do alvo.

O gráfico de distribuição do alvo mostra que o empate é a classe menos frequente, enquanto as vitórias da Seleção A são a classe mais comum. Isso indica que o problema não é perfeitamente balanceado. Por esse motivo, além da acurácia, foi usada a métrica macro-F1, que dá o mesmo peso para as três classes.





Figura 2: distribuição dos resultados por Copa.

O gráfico por Copa mostra que todas as edições possuem 64 partidas, mas a distribuição entre vitória da Seleção A, empate e vitória da Seleção B muda de um ano para outro. Essa variação reforça a escolha de validação temporal, pois o modelo precisa ser avaliado em Copas futuras, não em partidas misturadas aleatoriamente.

A análise exploratória mostrou relação clara entre diferença de ranking e resultado. Quando a Seleção A estava muito melhor ranqueada, a frequência de vitória de A foi maior; quando a Seleção B estava melhor ranqueada, a frequência de vitória de B aumentou.

As faixas do gráfico usam $\text{diff_rank} = \text{ranking da Seleção A} - \text{ranking da Seleção B}$. Assim, A muito melhor indica diferença menor que -30 posições; A melhor, de -30 a -10; Equilibrado, de -10 a 10; B melhor, de 10 a 30; e B muito melhor, acima de 30 posições.



$\text{diff_rank} = \text{ranking da Seleção A} - \text{ranking da Seleção B}$. A muito melhor: < -30 ; A melhor: $-30 \text{ a } -10$; Equilibrado: $-10 \text{ a } 10$; B melhor: $10 \text{ a } 30$; B muito melhor: > 30 .

Figura 3: resultado por faixa de diferença de ranking FIFA.

O gráfico de diferença de ranking é o principal indício exploratório a favor da hipótese H1. A frequência de vitórias da Seleção A cai conforme a vantagem de ranking passa para a Seleção B, enquanto a frequência de vitórias da Seleção B aumenta. Embora ainda existam empates e resultados inesperados, a tendência geral mostra que o ranking possui informação preditiva relevante.

Modelo	Conjunto	Acurácia	Macro-F1
Baseline	Validação 2014	0,4531	0,2079
Baseline	Teste 2018	0,3906	0,1873
Regressão logística	Validação 2014	0,4531	0,3789
Regressão logística	Teste 2018	0,5000	0,4761
Árvore de decisão	Validação 2014	0,3438	0,3524
Árvore de decisão	Teste 2018	0,4062	0,3988
Random forest	Validação 2014	0,4844	0,4127
Random forest	Teste 2018	0,4219	0,3668




Figura 4: comparação dos modelos por macro-F1.




Figura 5: matriz de confusão do melhor modelo no teste de 2018.

Grupo de atributos	Acurácia	Macro-F1	Variáveis
Ranking FIFA	0,5938	0,4799	6
Ranking + forma recente	0,5312	0,4617	15
Ranking + forma + ciclo	0,4688	0,3931	28
Completo sem força adversários	0,4375	0,3887	29
Modelo completo	0,4531	0,3789	32




Figura 6: principais variáveis segundo o random forest.

A avaliação das hipóteses indica que H1 foi a mais apoiada, pois o grupo de ranking FIFA obteve o melhor desempenho na validação. H2 recebeu apoio parcial: a forma recente apresentou desempenho próximo ao ranking, mas não o superou. H3 também recebeu apoio parcial, já que variáveis do ciclo tiveram resultado competitivo em alguns cenários, mas sem ganho consistente na validação. H4 não foi confirmada de forma clara, pois a força dos adversários recentes não melhorou o modelo completo na validação.

6. Discussão e Conclusão

Os resultados indicam que é possível prever parcialmente os resultados da Copa usando informações prévias ao torneio. Os modelos treinados superaram o baseline em macro-F1, sugerindo que os atributos carregam algum sinal preditivo. No teste final de 2018, a regressão logística obteve 50% de acurácia e macro-F1 de 0,4761.

A hipótese mais apoiada foi H1, relacionada ao ranking FIFA. O grupo de atributos de ranking obteve o melhor resultado na validação de 2014. A inclusão de muitas variáveis de ciclo e forma recente não melhorou consistentemente o desempenho, possivelmente por causa do tamanho reduzido da amostra e da alta variabilidade do futebol.

Como limitações, destacam-se o número pequeno de partidas, a ausência de variáveis contextuais como escalações e lesões, e a dificuldade natural de prever empates. Ainda assim, o projeto fornece uma base adequada para investigar fatores associados ao desempenho em Copas do Mundo.

Referências e Bases de Dados

Mart Jürisoo. International football results from 1872 to 2026. Kaggle.

<https://www.kaggle.com/datasets/martj42/international-football-results-from-1872-to-2017>

Lucas Yukio Imafuko. FIFA Men's World Ranking. Kaggle.

<https://www.kaggle.com/datasets/lucasyukioimafuko/fifa-mens-world-ranking>

Scikit-learn. User Guide: supervised learning and model evaluation.

https://scikit-learn.org/stable/user_guide.html

Hastie, T.; Tibshirani, R.; Friedman, J. The Elements of Statistical Learning. Springer.

James, G.; Witten, D.; Hastie, T.; Tibshirani, R. An Introduction to Statistical Learning. Springer.