

Predição de Resultados de Partidas da Copa do Mundo

Uma abordagem com ranking FIFA e desempenho pré-Copa
Integrante 1 · Integrante 2 · Integrante 3 · Integrante 4

Sumário

1. Contexto, Motivação e Objetivo

Contexto; Motivação; Objetivo

2. Enquadramento Analítico

3. Hipóteses Sobre o Fenômeno

4. Metodologia e Modelagem

Construção do Dataset; Prevenção de Vazamento Temporal; Engenharia e Seleção de Atributos; Estratégia de Validação

5. Dados e Resultados

Análise Exploratória; Resultados da Modelagem; Avaliação das Hipóteses; Testes Estatísticos

6. Discussão e Conclusão

Referências e Bases de Dados

1. Contexto, Motivação e Objetivo

Contexto

A Copa do Mundo FIFA é uma das competições esportivas mais acompanhadas do mundo. Além do interesse esportivo, o torneio oferece um cenário rico para análise de dados, pois envolve seleções de diferentes continentes, históricos competitivos distintos, rankings internacionais e partidas de alta pressão.

Motivação

A análise de dados aplicada ao esporte, conhecida como sports analytics, é usada para apoiar decisões, avaliar desempenho e estimar probabilidades de resultados. No futebol, a previsão é especialmente difícil porque o resultado depende de fatores de curto prazo, como escalação, lesões, estratégia, expulsões e eventos aleatórios durante o jogo.

Objetivo

O objetivo é construir e avaliar modelos de classificação supervisionada para prever três classes: vitória da Seleção A, empate e vitória da Seleção B, usando somente informações disponíveis antes do início da Copa.

O dataset FIFA World Cup Dataset (2002-2026), indicado nas orientações do trabalho, foi analisado no planejamento do tema, mas não foi usado diretamente no processamento final. Ele possui estrutura mais voltada para desempenho de seleções em torneios, enquanto o objetivo deste

trabalho exige uma base em nível de partida. Por isso, foi construído um dataset derivado a partir de duas fontes principais: resultados internacionais de seleções e ranking FIFA.

A base de resultados internacionais foi usada porque contém datas, seleções, placares, torneios e informação de campo neutro, permitindo identificar partidas da Copa e calcular o histórico pré-Copa. A base de ranking masculino da FIFA foi usada porque fornece uma medida externa de força relativa das seleções antes do torneio. A combinação das duas bases permitiu criar atributos anteriores à Copa e prever cada jogo sem usar informações futuras. A edição de 2026 não foi usada porque ainda não possui resultados finais completos.

Os links completos das fontes utilizadas estão apresentados ao final do relatório, na seção de referências e bases de dados.

2. Enquadramento Analítico

O problema foi tratado como classificação multiclasse. Foram avaliados baseline da classe majoritária, regressão logística, árvore de decisão e random forest. As métricas principais foram acurácia e macro-F1, sendo a macro-F1 especialmente importante por equilibrar a avaliação entre as três classes.

A abordagem segue ideias comuns em sports analytics: usar medidas de força histórica, forma recente e comparação relativa entre adversários. No futebol, rankings, desempenho ofensivo, desempenho defensivo e forma prévia são frequentemente usados como aproximações da qualidade técnica e do momento competitivo das equipes.

3. Hipóteses Sobre o Fenômeno

- H1: seleções melhor posicionadas no ranking FIFA possuem maior probabilidade de vencer.
- H2: a forma recente acrescenta informação além do ranking.
- H3: o desempenho acumulado no ciclo pré-Copa contém informação útil.
- H4: a força dos adversários recentes melhora a interpretação da forma recente.

4. Metodologia e Modelagem

Construção do Dataset

O dataset derivado foi construído a partir de uma base de resultados internacionais e uma base de rankings semestrais da FIFA. Cada linha representa uma partida de Copa do Mundo entre 1998 e 2022.

Prevenção de Vazamento Temporal

Para evitar vazamento de informação, os atributos de cada Copa foram calculados apenas com dados anteriores ao início do torneio. O ciclo de uma Copa começa após a final da Copa anterior e termina antes da abertura da Copa analisada. O ranking utilizado foi sempre o do semestre anterior.

Engenharia e Seleção de Atributos

O pré-processamento incluiu padronização de nomes de seleções entre as bases, seleção das partidas de Copa, definição do ciclo pré-Copa e cálculo de estatísticas agregadas. Também foram criadas variáveis de diferença entre Seleção A e Seleção B, como diferença de ranking, pontos FIFA, aproveitamento recente, gols marcados e gols sofridos.

O dataset resultante possui 448 partidas e 45 colunas. Para a modelagem, foram removidos os placares reais, o alvo e metadados como nomes das seleções, datas e identificadores. Assim, os modelos utilizaram 32 variáveis explicativas.

Estratégia de Validação

A divisão temporal foi: treinamento nas Copas de 1998 a 2010, validação em 2014, teste final em 2018 e avaliação adicional em 2022. Essa divisão simula um cenário realista, em que o modelo aprende com Copas anteriores e é avaliado em Copas futuras.

Ferramentas Utilizadas

As ferramentas utilizadas foram Python, scikit-learn para modelagem, matplotlib e seaborn para visualizações, além de scripts próprios para geração do dataset, análise exploratória e avaliação dos modelos.

Trechos relevantes do código

O primeiro trecho mostra a prevenção de vazamento temporal: o ranking de cada seleção é buscado no semestre anterior ao início da Copa.

```
current_ranking = ranking.get_previous(team, tournament_start)
rank_year, rank_semester = ranking.previous_period(tournament_start)
```

O alvo da classificação foi gerado a partir do placar: vitória da Seleção A, empate ou vitória da Seleção B. Os placares foram removidos das variáveis explicativas usadas pelos modelos.

```
if score_a > score_b:
    result = 0
elif score_a == score_b:
    result = 1
else:
    result = 2
```

A avaliação foi organizada por tempo, usando Copas anteriores para treino e Copas posteriores para validação e teste.

```
if 1998 <= year <= 2010:
    treino.append(row)
elif year == 2014:
    validacao.append(row)
elif year == 2018:
    teste.append(row)
elif year == 2022:
    avaliacao_extra.append(row)
```

5. Dados e Resultados

O dataset final possui 448 partidas, 45 colunas e 67 seleções. Para a modelagem foram usadas 32 variáveis explicativas. A classe mais frequente é vitória da Seleção A, seguida por vitória da Seleção B e empate.

Análise Exploratória

A análise exploratória teve como objetivo compreender a composição do dataset antes da modelagem, verificar o equilíbrio entre as classes e observar relações iniciais entre força das seleções e resultado das partidas.




Figura 1: distribuição geral do alvo.

O gráfico de distribuição do alvo mostra que o empate é a classe menos frequente, enquanto as vitórias da Seleção A são a classe mais comum. Isso indica que o problema não é perfeitamente balanceado. Por esse motivo, além da acurácia, foi usada a métrica macro-F1, que dá o mesmo peso para as três classes.





Figura 2: distribuição dos resultados por Copa.

O gráfico por Copa mostra que todas as edições possuem 64 partidas, mas a distribuição entre vitória da Seleção A, empate e vitória da Seleção B muda de um ano para outro. Essa variação reforça a escolha de validação temporal, pois o modelo precisa ser avaliado em Copas futuras, não em partidas misturadas aleatoriamente.

A análise exploratória mostrou relação clara entre diferença de ranking e resultado. Quando a Seleção A estava muito melhor ranqueada, a frequência de vitória de A foi maior; quando a Seleção B estava melhor ranqueada, a frequência de vitória de B aumentou.

As faixas do gráfico usam $\text{diff_rank} = \text{ranking da Seleção A} - \text{ranking da Seleção B}$. Assim, A muito melhor indica diferença menor que -30 posições; A melhor, de -30 a -10; Equilibrado, de -10 a 10; B melhor, de 10 a 30; e B muito melhor, acima de 30 posições.



$\text{diff_rank} = \text{ranking da Seleção A} - \text{ranking da Seleção B}$. A muito melhor: < -30; A melhor: -30 a -10; Equilibrado: -10 a 10; B melhor: 10 a 30; B muito melhor: > 30.

Figura 3: resultado por faixa de diferença de ranking FIFA.

O gráfico de diferença de ranking é o principal indício exploratório a favor da hipótese H1. A frequência de vitórias da Seleção A cai conforme a vantagem de ranking passa para a Seleção B, enquanto a frequência de vitórias da Seleção B aumenta. Embora ainda existam empates e resultados inesperados, a tendência geral mostra que o ranking possui informação preditiva relevante.

Modelo	Conjunto	Acurácia	Macro-F1
Baseline	Validação 2014	0,4531	0,2079
Baseline	Teste 2018	0,3906	0,1873
Regressão logística	Validação 2014	0,4531	0,3789
Regressão logística	Teste 2018	0,5000	0,4761
Árvore de decisão	Validação 2014	0,3438	0,3524
Árvore de decisão	Teste 2018	0,4062	0,3988
Random forest	Validação 2014	0,4844	0,4127
Random forest	Teste 2018	0,4219	0,3668




Figura 4: comparação dos modelos por macro-F1.




Figura 5: matriz de confusão do melhor modelo no teste de 2018.

Grupo de atributos	Acurácia	Macro-F1	Variáveis
Ranking FIFA	0,5938	0,4799	6
Ranking + forma recente	0,5312	0,4617	15
Ranking + forma + ciclo	0,4688	0,3931	28
Completo sem força adversários	0,4375	0,3887	29
Modelo completo	0,4531	0,3789	32




Figura 6: principais variáveis segundo o random forest.

A avaliação das hipóteses indica que H1 foi a mais apoiada, pois o grupo de ranking FIFA obteve o melhor desempenho na validação. H2 recebeu apoio parcial: a forma recente apresentou desempenho próximo ao ranking, mas não o superou. H3 também recebeu apoio parcial, já que variáveis do ciclo tiveram resultado competitivo em alguns cenários, mas sem ganho consistente na validação. H4 não foi confirmada de forma clara, pois a força dos adversários recentes não melhorou o modelo completo na validação.

Testes Estatísticos das Hipóteses

Além da comparação preditiva, foram executados testes estatísticos para avaliar associação entre atributos e resultado. Foram usados qui-quadrado de independência para variáveis categorizadas e correlação de Spearman para atributos numéricos. O resultado foi convertido para escala direcional: vitória da Seleção A = 1, empate = 0 e vitória da Seleção B = -1.

O qui-quadrado foi escolhido porque o alvo é categórico e algumas hipóteses foram avaliadas por faixas, como diferença de ranking e vantagem de forma recente. Esse teste verifica se a distribuição dos resultados muda entre os grupos. Como complemento, foi usado o V de Cramer para medir o tamanho do efeito, já que o p-valor indica associação, mas não informa sua intensidade.

A correlação de Spearman foi escolhida para atributos numéricos porque mede associação monotônica sem exigir normalidade dos dados. Isso é adequado para variáveis como diferença de ranking, pontos FIFA e aproveitamento pré-Copa, que podem não seguir distribuição normal. Esses testes complementam a modelagem preditiva e indicam associação, não causalidade.

Hipótese	Teste principal	p-valor	Efeito
H1 - Ranking FIFA	Qui-quadrado	<0,001	V=0,252
H2 - Forma recente	Qui-quadrado	<0,001	V=0,167
H3 - Ciclo pré-Copa	Qui-quadrado	<0,001	V=0,173

Hipótese	Teste principal	p-valor	Efeito
H4 - Força dos adversários	Qui-quadrado	0,468	V=0,058

Os testes reforçam que ranking FIFA, forma recente e desempenho no ciclo pré-Copa possuem associação estatística com o resultado. O maior efeito foi observado em H1, confirmando o ranking como fator mais consistente. A H4 não apresentou evidência forte no qui-quadrado, embora a correlação de Spearman para força dos adversários tenha sido significativa, porém fraca.

6. Discussão e Conclusão

Os resultados indicam que é possível prever parcialmente os resultados da Copa usando informações prévias ao torneio. Os modelos treinados superaram o baseline em macro-F1, sugerindo que os atributos carregam algum sinal preditivo. No teste final de 2018, a regressão logística obteve 50% de acurácia e macro-F1 de 0,4761.

A hipótese mais apoiada foi H1, relacionada ao ranking FIFA. O grupo de atributos de ranking obteve o melhor resultado na validação de 2014. A inclusão de muitas variáveis de ciclo e forma recente não melhorou consistentemente o desempenho, possivelmente por causa do tamanho reduzido da amostra e da alta variabilidade do futebol.

Como limitações, destacam-se o número pequeno de partidas, a ausência de variáveis contextuais como escalações e lesões, e a dificuldade natural de prever empates. Ainda assim, o projeto fornece uma base adequada para investigar fatores associados ao desempenho em Copas do Mundo.

Referências e Bases de Dados

Mart Jürisoo. International football results from 1872 to 2026. Kaggle.

<https://www.kaggle.com/datasets/martj42/international-football-results-from-1872-to-2017>

Lucas Yukio Imafuko. FIFA Men's World Ranking. Kaggle.

<https://www.kaggle.com/datasets/lucasyukioimafuko/fifa-mens-world-ranking>

Scikit-learn. User Guide: supervised learning and model evaluation.

https://scikit-learn.org/stable/user_guide.html

Hastie, T.; Tibshirani, R.; Friedman, J. The Elements of Statistical Learning. Springer.

James, G.; Witten, D.; Hastie, T.; Tibshirani, R. An Introduction to Statistical Learning. Springer.